Метод 2: символьные n-граммы, TF-IDF и логистическая регрессия

У автора есть «почерк» в языке: любимые слова, привычные сочетания букв, особенности построения фраз. Если научить модель замечать такие привычки, она сможет подсказывать, кто мог написать текст.

ЧТО МЫ ИМЕЕМ:

- **Всего:** 738 записей – каждая запись:одно стихотворение или его часть.
- **Объём:** 9459 бейтов.
- **Использовано:** 716 записей после проверки на повторы и т.д.

Размеры очень разные: у Антары 158 записей, а у аль-Хариса только 19. Выборка получается небольшой:

Оставлено для работы	716
Исключено как повтор внутри одного поэта (16 записей)	16
Исключено из-за общего бейта у разных поэтов (6 записей)	6
Итого	738

ПРО МЕТОД:

В арабском письме над буквами и под ними могут стоять маленькие значки – огласовки. Они подсказывают, как читать гласные: например, «ба», «би», «бу» пишутся одной базовой буквой, но с разными значками. В разных изданиях стихов их ставят по-разному или не ставят совсем.

Чтобы модель не приняла различия оформления за различия авторов, я убрала огласовки и ещё несколько отличий: растяжки букв, разные формы одной и той же буквы «алиф» и лишние пробелы. Между половинами бейта я поставила знак «|», а между бейтами — «#», чтобы сохранить структуру стиха.

Кроме того, в каждом бейте я убрала последнее слово, потому что конец бейта в арабском стихе рифмуется и часто сильно определяется самой формой стихотворения. В этом методе нам важнее обычная манера письма, а не рифмующее слово.

ПОДСЧЁТ СОЧЕТАНИЯ БУКВ:

Модель считает, как часто встречаются короткие цепочки символов – их называют символьными n-граммами. Число n показывает длину цепочки.

Для условного слова «kataba» получаются такие цепочки:

Длина	Название	Что получается
1	отдельные буквы	k, a, t, a, b, a
2	пары	ka, at, ta, ab, ba
3	тройки	kat, ata, tab, aba
4	четвёрки	kata, atab, taba

Я использовала цепочки длиной от 1 до 4 символов. Это как подсчёт, какие слоги, окончания и приставки автор употребляет чаще. Такой подход не требует знать грамматику языка и поэтому подходит для арабского текста.

ИДЕЯ – ПРИДАТЬ БОЛЬШИЙ ВЕС «ХАРАКТЕРНЫМ» СОЧЕТАНИЯМ; НАУЧИТЬ КЛАССИФИКАТОР РАЗЛИЧАТЬ АВТОРОВ:

Частое сочетание не всегда полезно: если оно встречается у всех поэтов, оно ничего не отличает. Для этого применяется взвешивание TF-IDF. Если сочетание часто встречается в тексте, но редко в других текстах, оно получает больший вес; если встречается почти везде, вес меньше. Кроме того, длинные тексты не должны побеждать только потому, что они длиннее, поэтому итоговый набор чисел для текста приводится к единому масштабу.

После этого каждое стихотворение превращается в длинный список чисел. Дальше используется логистическая регрессия; ей показывают много «отпечатков» с известными авторами. Она подбирает правило, которое лучше всего различает поэтов, а затем применяет его к новым стихам.

Для длинных стихотворений при обучении я разделила текст на куски не более 10 бейтов. Так модель получает больше примеров. Но при проверке стихотворение всегда оценивается целиком.

Если проверять модель на тех же стихах, на которых он учился, результат будет завышен. Поэтому я разделила целые стихотворения на независимые группы:

Группа	Произведений	Для чего нужна
Обучение	317	Модель учится различать поэтов
Настройка вероятностей	106	Подгоняем «уверенность» модели к реальности
Эталоны для p-value	141	Хранят типичные примеры каждого поэта
Проверка	142	Итог: эти стихи модель раньше не видела
Муаллаки	10	Отдельная диагностика самых известных поэм

Один и тот же текст не мог оказаться сразу в двух группах. Ещё я удалила повторы и записи, у которых есть общий бейт с текстом другого поэта, чтобы такие совпадения не подсказывали ответ.

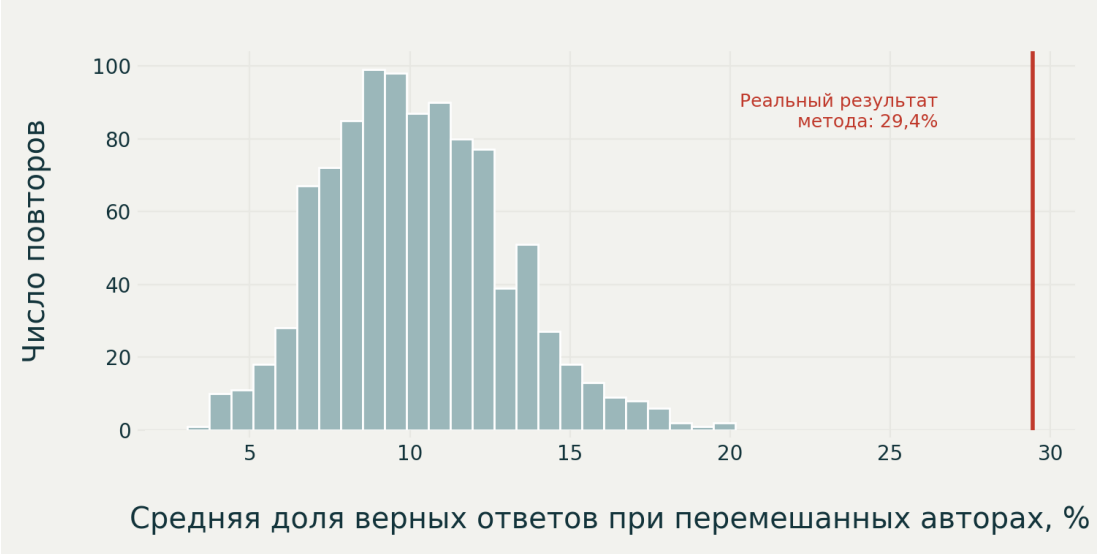
ПРО p-value:

Использую два разных p-value: для всего метода в целом и для отдельного стихотворения.

Что было бы, если бы авторы были подписаны наугад? Для проверки я случайно перемешала авторские подписи у стихотворений и заново обучила модель. Это сделала 999 раз и каждый раз измеряла среднюю долю верных ответов по авторам. Затем сравнила с реальным результатом.

Реальный результат – 29,4%. При перемешанных подписях модель в среднем давала около 10,2%, а лучший случайный результат был 20,2%. Ни один из 999 случайных вариантов не достиг

реального результата. Поэтому p = 0,001. Это минимальное значение для 999 повторов: меньшего не получить без большего числа проверок.



Вывод: связь между текстом и поэтом в коллекции есть, и это не просто совпадение.

Теперь, если считать, что автор указан верно, насколько этот текст необычен на фоне других эталонных стихов этого поэта? Если текст оказывается очень необычным, p-value становится малым; чем меньше эталонов у автора, тем грубее p-value. Например, у аль-Хариса всего 4 эталона, поэтому его минимально возможное p-value – 0,2. При обычном пороге 0,05 у такого автора невозможно «убрать» авторство вообще, даже если текст чужой. У Антары 31 эталон, и минимум составляет 0,031.

РЕЗУЛЬТАТЫ:

Показатель	Результат	Интерпретация
Проверочных произведений	142	Стихи, которые модель раньше не видела
Верно названо	53 из 142 (37,3%)	Совпадение с автором, указанным в коллекции
Средняя доля верных ответов по авторам	29,4%	Каждый поэт имеет одинаковый вес; при угадывании было бы около 10%
Всегда называть самого частого автора	21,8% верных	Простейший «ленивый» вариант для сравнения
p-value метода	0,001	Результат трудно объяснить случайностью
Размер набора кандидатов при уровне 5%	в среднем 9,3 из 10	Осторожная процедура почти никого не исключает

Модель действительно лучше случайного угадывания: 29,4% против примерно 10%. Но она ошибается чаще, чем угадывает: из 142 стихотворений верно определены только 53. Для надёжного суждения о конкретном стихотворении этого мало.



Лучше всего распознаётся Антара: 24 из 31 стихотворений (77%). Это один из самых больших корпусов в нашей коллекции, поэтому у модели много примеров его стиля. Хорошо идут и стихи аль-Аши (10 из 16). Совсем не удалось узнать аль-Хариса (0 из 3) и Тарафу (0 из 7). Числа у них маленькие, и делать вывод «их нельзя распознать» неправильно: правильнее сказать, что примеров недостаточно.

ЧАЩЕ ВСЕГО ПУТАЮТСЯ:

Например, из 24 стихотворений Лабида модель восемь раз выбрала аль-Ашу. Из 21 стихотворения ан-Набиги пять раз назвала аль-Ашу и пять раз Лабида. Возможные причины: общие темы, одна эпоха и форма стиха, а также различия в объёме данных.

НА ПРИМЕРЕ ОДНОГО СТИХОТВОРЕНИЯ:

Возьмём стихотворение Антары № 187 из трёх бейтов. Модель выбрала Ан-Набигу, то есть ошиблась по меткам коллекции. Модельная вероятность метки «Антара» равна около 6,5%, а p-value для Антары – 0,031. Это сигнал, что текст нетипичен для эталонов Антары. Но после поправки на множество проверок значимое отклонение исчезает ($p = 1$).